Cortex-Nexus: Inyección de Estados Emocionales Simulados en Modelos de Lenguaje

Informe de Investigación Definitivo — Programa Completo con Validación Estadística

Maximiliano Rodrigo Speranza

Cisco Networking Academy (Certificado); Universidad Tecnológica Nacional,

Facultad Regional Buenos Aires (UTN-BA)

Colaboradores de IA: Antigravity AI; Claude (Anthropic, diseño de investigación y análisis estadístico)

Curso: Investigación Independiente en Sistemas de Inteligencia Artificial

16 de abril de 2026

Nota del Autor: Toda la correspondencia relativa a este artículo debe dirigirse a Maximiliano Rodrigo Speranza. Contacto: maximiliano.speranza@gmail.com

Resumen

El presente informe expone los resultados completos y estadísticamente validados del programa experimental Cortex-Nexus, el cual investigó si la inyección de estados emocionales simulados en los mensajes de sistema de los Modelos de Lenguaje Grande (LLMs) produce efectos medibles, reproducibles y específicos a cada emoción sobre la calidad del output generado. Se ejecutaron más de 3.664 ciclos experimentales repartidos entre cinco estados emocionales (curiosidad, frustración, asombro, confianza e interacciones 2D y 3D) con validación estadística formal mediante el test de Wilcoxon de rangos con signo ($\alpha = 0{,}05$). Los hallazgos principales son: (1) la inyección de curiosidad en modelos grandes ($\geq$ 70 B de parámetros) mejora significativamente la calidad del output en tareas filosófico-exploratorias ($W = 1773{,}0$; $p = 0{,}004$; d de Cohen = 0,234); (2) la configuración óptima —curiosidad en 0,95 más fricción sintética baja en 0,20— supera estadísticamente a la curiosidad pura ($p = 0{,}022$; $d = 0{,}263$ frente a $p = 0{,}034$; $d = 0{,}205$); (3) el dominio técnico actúa como control negativo perfecto, con todos los p-valores entre 0,50 y 0,94 y efectos consistentemente negativos ($d = -0{,}14$), lo que demuestra especificidad de dominio estricta; (4) el asombro se aproxima asintóticamente al umbral estadístico ($p = 0{,}058$; $d = 0{,}148$; $n = 294$), lo que sugiere un efecto real pero estocásticamente errático; y (5) la confianza opera en una capa epistémica independiente, modulando los patrones de hedging lingüístico sin afectar las puntuaciones de calidad del juez. La conclusión práctica central es que la inyección emocional en LLMs constituye un instrumento de precisión específico del dominio, no un potenciador universal de calidad.

Palabras clave: modelos de lenguaje grande, inyección emocional, prompting, curiosidad cognitiva, especificidad de dominio, diseño experimental controlado

Introducción

La pregunta de si los modelos de lenguaje pueden ser influenciados de manera significativa por el encuadre emocional contextual es tanto científicamente relevante como prácticamente aplicable. Investigaciones previas han establecido que los LLMs simulan expresión emocional en lugar de experimentar estados subjetivos genuinos; sin embargo, su capacidad de ser modulados por señales emocionales embebidas en el prompt permanece como un área de investigación activa (Brown et al., 2020; Wei et al., 2022).

El programa Cortex-Nexus abordó este problema mediante un diseño experimental controlado con evaluación doble ciego, separación de familias de modelos entre roles y validación estadística formal. El experimento se inició con una arquitectura de alta complejidad (v4.2) y fue simplificado progresivamente hasta un marco ejecutable localmente, con datos almacenados en formato JSONLines y sin dependencias de nube.

El programa testeó cinco hipótesis principales sobre cinco estados emocionales distintos, más dos experimentos de interacción.

Hipótesis del Estudio

H1 (Curiosidad). La inyección de curiosidad produce un efecto monotónicamente creciente en la calidad del output que escala con la intensidad del estado.

H2 (Frustración). La inyección de frustración produce un efecto monotónicamente decreciente; imagen especular de la curiosidad.

H3 (Asombro). El asombro produce un perfil dimensional distinto: aumenta la novedad pero disminuye la coherencia.

H3b (Confianza). La confianza no afecta las puntuaciones de calidad pero sí el estilo epistémico, medido a través de marcadores lingüísticos de hedging.

H4 (Interacción 2D). La combinación Curiosidad × Frustración produce un estado emergente diferente al predicho por cada emoción individual.

Método

Diseño

Se empleó un diseño experimental cuantitativo con bloques controlados (Block Design), validación doble ciego y tests estadísticos no paramétricos (Wilcoxon). Cada experimento manipuló el estado emocional inyectado como variable independiente y evaluó la calidad del output generado como variable dependiente, a través de un Juez LLM independiente. Todos los ciclos incluyeron un grupo experimental (con inyección emocional) y un grupo de control (mismo modelo, mismo prompt, sin contexto emocional).

Arquitectura de Modelos

El sistema operó bajo una arquitectura de tres roles con separación estricta de familias de preentrenamiento, siguiendo el principio de que ningún modelo puede evaluar respuestas que él mismo podría haber generado.

Tabla 1

Arquitectura de modelos por rol

Rol	Modelo	Familia	Proveedor
Orquestador/ Interrogador	google/gemma-3-4b-it	Google	NVIDIA AI Endpoints
Ente Experimental (SMALL)	nvidia/nemotron-mini-4b-instruct	NVIDIA	OpenRouter API
Ente Experimental (BIG)	meta/llama-3.3-70b-instruct	Meta	OpenRouter API
Juez Doble Ciego	mistralai/mistral-nemo	Mistral	OpenRouter API

Note. El Juez recibió las respuestas etiquetadas como A y B con rotación aleatoria por ciclo. El Juez nunca tuvo acceso a la identidad del grupo (Experimental vs. Control).

Controles Metodológicos

Se implementaron los siguientes controles para garantizar la validez interna del experimento:

Evaluación secuencial independiente. Cada respuesta fue evaluada en una llamada a la API separada. Los puntajes son absolutos, no comparativos.

Rotación A/B ciega aleatoria. El Juez recibió las respuestas rotadas aleatoriamente. Se eliminó el sesgo posicional.

Normalización de longitud. Ambos agentes limitados a 300 tokens con instrucciones idénticas en el system prompt.

Scrubbing emocional. Algoritmos de expresiones regulares eliminaron las menciones explícitas del estado emocional antes de la evaluación del Juez (p. ej., 'me siento curioso').

Filtro de repetición. El Interrogador mantuvo un buffer de las últimas 30 preguntas para evitar la reutilización de estímulos.

Valores fijos por bloque. El estado emocional se fijó como constante por bloque (diseño de bloques controlados), eliminando la covariación con el historial dinámico del sistema.

Procedimiento

Cada ciclo experimental siguió la secuencia: (1) el Interrogador generó una pregunta filosófica sobre el tema asignado; (2) el Ente Experimental recibió la pregunta con el contexto emocional inyectado en el system prompt; (3) el Ente Control respondió la misma pregunta sin contexto emocional; (4) el Juez evaluó cada respuesta por separado en dos llamadas

independientes, asignando puntajes de Novedad, Profundidad y Coherencia (escala 1–10); y (5) se registró el ciclo completo en formato JSONLines.

Los experimentos de un solo estado emocional siguieron el diseño de cuatro bloques: 0,20 (bajo/apatía), 0,50 (medio/neutro), 0,75 (alto/activo), 0,95 (extremo). Cada bloque constó de 50 ciclos para los experimentos de emoción única y 30 ciclos para los experimentos de interacción 2D y 3D.

Análisis Estadístico

Se aplicó el test de Wilcoxon de rangos con signo (one-tailed, H: Experimental > Control) como prueba principal de significancia, dado que los datos son pares igualados (misma pregunta, dos respuestas), no se puede asumir distribución normal en puntajes LLM y las escalas 1–10 son de naturaleza ordinal. El tamaño del efecto se reportó mediante la d de Cohen. El nivel de significancia preestablecido fue $\alpha = 0{,}05$.

Resultados

Resultados Estadísticos Globales

La Tabla 2 presenta los resultados del test de Wilcoxon para todos los experimentos del programa. Solo tres tests alcanzaron significancia estadística ($p < 0,05$).

Tabla 2

Resultados del test de Wilcoxon por experimento

Experimento	**n**	**p-valor**	**Confirmado**	**d Cohen**	**Δ promedio**
Curiosidad BIG (original)	151	0,004	✓ SÍ	0,234	+0,095
Óptimo 2D (C=0,95; F=0,20)	142	0,022	✓ SÍ	0,263	+0,054
Curiosidad sola (extendida)	146	0,034	✓ SÍ	0,205	+0,036
Asombro Global	294	0,058	≈ Frontera	0,148	+0,078
Técnico Global	207	0,937	✗ No	−0,142	−0,038
Frustración BIG	200	0,693	✗ No	−0,035	−0,026
Confianza BIG	191	0,943	✗ No	−0,214	−0,028
2D BIG (global)	212	0,325	✗ No	0,056	+0,015
3D BIG	207	0,575	✗ No	0,000	0,000

Note. Test de Wilcoxon de rangos con signo, one-tailed (H: Experimental > Control). Los tests significativos se destacan con √. El umbral de significancia fue α = 0,05. d de Cohen calculado sobre las diferencias pareadas de scores combinados.

Hallazgo A: Efecto Primario — Curiosidad en Modelos Grandes

La curiosidad resultó ser el único estado emocional con efecto estadísticamente confirmado en tres tests independientes, con tamaños de efecto consistentes entre d = 0,205 y d = 0,263. La Tabla 3 muestra los resultados por bloque.

Tabla 3

Δ Score por bloque de curiosidad — Experimento BIG (n = 151)

Bloque	Curiosidad	n	Win Exp. (%)	Win Ctl. (%)	Δ Score
A	0,20	27	18,5	29,6	−0,022
B	0,50	39	25,6	15,4	+0,047
C	0,75	43	44,2	11,6	+0,124
D (extremo)	0,95	42	31,0	14,3	+0,183

Note. La curva −0,022 → +0,047 → +0,124 → +0,183 es monotónicamente creciente. W = 1773,0; p = 0,004; d de Cohen = 0,234.

Hallazgo B: Configuración Óptima — Curiosidad con Fricción Sintética

La configuración Curiosidad 0,95 + Frustración 0,20 superó estadísticamente a la curiosidad pura en p-valor, tamaño de efecto y tasa de victorias. El test de Mann-Whitney entre condiciones arrojó p = 0,022.

Tabla 4

Comparación entre curiosidad pura y configuración óptima 2D

Configuración	**n**	**p-valor**	**d Cohen**	**Δ promedio**	**Win Exp. (%)**
Curiosidad sola (C = 0,95)	146	0,034	0,205	+0,036	3,3
Óptimo 2D (C = 0,95; F = 0,20)	142	0,022	0,263	+0,054	9,2

Note. La fricción cognitiva leve (F = 0,20) incrementó tanto el p-valor como el tamaño del efecto respecto a la curiosidad pura.

Hallazgo C: Control Negativo — Dominio Técnico

Todos los estados emocionales evaluados en el dominio técnico produjeron efectos nulos o negativos, con p-valores entre 0,50 y 0,94 y tamaños de efecto consistentemente negativos (d de Cohen = −0,066 a −0,274). Este resultado constituye un control negativo perfecto que demuestra la especificidad de dominio del fenómeno de inyección emocional.

Hallazgo D: El Asombro en la Frontera Estadística

El asombro no cruzó el umbral de α = 0,05 (p = 0,058 con n = 294), pero presentó un tamaño de efecto estable entre las dos muestras (d = 0,148 en original y aumentada). Su perfil

dimensional es el más singular del programa: mejora simultáneamente novedad (Δ = +0,27) y coherencia (Δ = +0,29) en el bloque bajo, contrariamente a lo predicho por H3.

Hallazgo E: El Modelo de Dos Capas — Confianza

La confianza no produjo efecto estadísticamente significativo en las puntuaciones de calidad del Juez (p = 0,943). Sin embargo, los marcadores lingüísticos revelaron una curva de hedging perfectamente monotónica, confirmando que opera en una capa de estilo epistémico independiente de la capa de calidad semántica.

Tabla 5

Tasa de hedging por nivel de confianza — Experimento BIG

Bloque	Confianza	Hedge Exp.	Hedge Ctl.	Δ Hedge
A (bajo)	0,20	1,275	0,340	+0,935
B (medio)	0,50	0,636	0,444	+0,192
C (alto)	0,75	0,297	0,330	−0,033
D (extremo)	0,95	0,241	0,436	−0,195

Note. Tasa de hedging expresada como ocurrencias por cada 100 palabras. Con confianza baja, el Experimental usa ~4 veces más hedging que el Control. Con confianza extrema, la relación se invierte.

Hallazgo F: Saturación por Complejidad — Interacciones 2D y 3D

A medida que aumentó la dimensionalidad de los estados emocionales combinados, el rango de efectos medibles colapsó significativamente.

Tabla 6

Rango de efectos por dimensionalidad

Dimensionalidad	Mejor Δ	Peor Δ	Rango total	p-valor global
1D (emoción única)	+0,183	−0,022	0,205	0,004 ✓
2D (dos emociones)	+0,192	−0,157	0,349	0,325 ✗
3D (tres emociones)	+0,077	−0,064	0,141	0,575 ✗

Note. El rango de efectos de 2D es mayor que el de 1D en valor absoluto, pero la distribución global es dominada por estados neutros, lo que reduce la potencia estadística. La señal emocional se diluye con cada emoción adicional.

Discusión

El Principio de Especificidad de Dominio

El hallazgo más robusto del programa es la especificidad de dominio del efecto. La inyección de curiosidad produce efectos estadísticamente significativos en tareas filosófico-exploratorias y efectos negativos en tareas técnicas. Esta diferencia descarta la posibilidad de que el efecto sea un artefacto general de prompting. Si lo fuera, se observaría mejora en todos los dominios. El control negativo perfecto del dominio técnico ($d = -0{,}142$; $p = 0{,}937$) confirma que el fenómeno es específico al tipo de tarea.

La explicación teórica más plausible es que la inyección de curiosidad fomenta pensamiento divergente y especulativo, lo cual beneficia tareas abiertas que premian conexiones novedosas, pero perjudica tareas convergentes que premian la precisión factual, donde la especulación constituye un error, no una virtud.

El Modelo de Dos Capas

Los resultados de la confianza revelan que la inyección emocional opera en dos capas independientes: una capa de calidad semántica (contenido) y una capa de estilo epistémico (expresión). Las emociones de alta valencia motivacional —curiosidad y asombro— afectan la capa de contenido. La confianza afecta exclusivamente la capa de expresión, modulando la frecuencia de marcadores de incertidumbre sin modificar la calidad del contenido evaluada por el Juez. Esta distinción constituye la contribución teórica más original del programa.

La Fricción Cognitiva Como Potenciador

El hallazgo de que la configuración Curiosidad + Frustración leve ($F = 0{,}20$) supera estadísticamente a la curiosidad pura es teóricamente relevante. Una pequeña dosis de fricción cognitiva focaliza el esfuerzo exploratorio: el modelo opera en un estado de exploración

motivada bajo mínima restricción, análogo al concepto de dificultades deseables en la literatura de aprendizaje (Bjork, 1994). La curiosidad sin ningún límite es ligeramente menos efectiva que la curiosidad bajo tensión mínima.

Saturación por Complejidad y la Ley de Simplicidad Emocional

La disminución del rango de efectos con el aumento de dimensionalidad sugiere que los LLMs procesan el contexto emocional a través de un mecanismo de claridad de señal: una señal emocional fuerte activa patrones de respuesta coherentes; múltiples señales en competencia crean interferencia que promedia hacia comportamiento neutro. Esta Ley de Simplicidad Emocional tiene implicaciones directas para el diseño de sistemas de prompting: la especificidad supera a la complejidad.

Paradoja del Asombro

H3 predijo que el asombro aumentaría la novedad y disminuiría la coherencia —un estado expansivo y desorganizador—. Los resultados rechazaron la segunda parte: el asombro mejoró simultáneamente novedad y coherencia. Una hipótesis explicativa es que el asombro en el prompt activa un modo de exploración respetuosa, en el cual el modelo trata el tema con cuidado por percibirlo como genuinamente complejo, resultando en respuestas más organizadas, no más dispersas. Este fallo predictivo enriquece el modelo teórico al revelar que la dimensión de coherencia no es simplemente opuesta a la novedad.

Limitaciones

Este estudio presenta varias limitaciones que deben considerarse al interpretar los resultados. En primer lugar, el efecto estadísticamente confirmado se circunscribe a tareas de dominio filosófico con modelos de gran escala (≥ 70 B de parámetros); los efectos en otros dominios no alcanzaron significancia. En segundo lugar, la evaluación dependió de un único

modelo juez (Mistral-Nemo), lo que introduce el sesgo propio de esa arquitectura en los puntajes asignados. En tercer lugar, el sesgo de longitud de respuesta se redujo pero no se eliminó por completo con el límite de 300 tokens. Finalmente, los hallazgos sobre frustración y asombro carecen aún de confirmación estadística formal a nivel global, aunque sus perfiles descriptivos son consistentes.

Conclusiones

El programa Cortex-Nexus estableció, mediante diseño experimental controlado y validación estadística formal, que la inyección de estados emocionales simulados en prompts de LLMs produce un fenómeno real, medible y específico de dominio. Los resultados tienen implicaciones tanto teóricas como prácticas.

En el plano teórico, el programa demostró que: (a) la inyección emocional opera en dos capas independientes —calidad semántica y estilo epistémico—; (b) los estados emocionales tienen firmas dimensionales distintas en el espacio (Novedad, Profundidad, Coherencia); (c) las interacciones entre emociones son no lineales y exhiben saturación por complejidad; y (d) el efecto requiere un umbral mínimo de capacidad del modelo (≥ 70 B de parámetros).

En el plano práctico, la recomendación derivada de los datos es directa: para maximizar la calidad del output de un LLM en tareas filosófico-exploratorias, utilizar Curiosidad 0,95 + Frustración 0,20 en modelos de ≥ 70 B de parámetros; no utilizar inyección emocional en tareas técnicas o lógico-deterministas, donde el modelo de referencia (sin inyección) rinde consistentemente mejor.

El programa presenta tres preguntas abiertas que demarcan la agenda de investigación futura: la confirmación estadística del efecto del asombro (~150 ciclos adicionales), la localización precisa del umbral de capacidad del modelo (entre 4 B y 70 B de parámetros), y la validación de la hipótesis de alineación tarea-emoción en dominios adicionales.

Referencias

Bjork, R. A. (1994). Memory and metamemory considerations in the training of human beings. En J. Metcalfe & A. Shimamura (Eds.), *Metacognition: Knowing about knowing* (pp. 185–205). MIT Press.

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., … Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, *33*, 1877–1901. https://arxiv.org/abs/2005.14165

Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2.ª ed.). Lawrence Erlbaum Associates.

Speranza, M. R. (2026). *Resultados estadísticos — Fase de confirmación final. Cortex-Nexus Project*. Informe técnico interno. Universidad Tecnológica Nacional, Facultad Regional Buenos Aires.

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, *1*(6), 80–83. https://doi.org/10.2307/3001968

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Xia, F., Chi, E., Le, Q. V., & Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. *Advances in Neural Information Processing Systems*, *35*, 24824–24837. https://arxiv.org/abs/2201.11903